

DOI: 10.19650/j.cnki.cjsi.J2006525

基于 MSCKF 的 IMU 与激光雷达紧耦合定位方法^{*}

吕 攀, 辛 越, 张 恒, 李 红, 杨国青
(浙江大学计算机科学与技术学院 杭州 310027)

摘 要: 针对传统移动机器人定位方法对计算资源要求较高, 而其所采用的嵌入式处理器通常计算力不足的问题, 提出了一种低计算复杂度的移动机器人定位方法。该定位方法使用多状态约束下的卡尔曼滤波器对激光雷达和 IMU 数据进行融合, 同时采用近似近邻搜索方法取代传统的 KD 树近邻搜索方法来进行激光点云法向量的提取, 在符合平面特征提取精度要求的前提下, 法向量提取速度提高了近 6 倍。最后, 在地下车库场景下对该定位方法进行了测试, 该方法整体定位误差在 0.4 m 以内, 旋转绝对位姿误差集中在 0.02~0.06 rad 之间。实验结果表明, 所提方法占用较少的计算资源, 在结构化环境中能够提供良好的定位结果。

关键词: 定位; 卡尔曼滤波器; 激光雷达; 惯性测量单元; 平面特征提取

中图分类号: TP242.6 TH76 **文献标识码:** A **国家标准学科分类代码:** 510.80

Tightly coupled localization of IMU and lidar based on MSCKF

Lyu Pan, Xin Yue, Zhang Heng, Li Hong, Yang Guoqing
(College of Computer Science & Technology, Zhejiang University, Hangzhou 310027, China)

Abstract: The traditional mobile robot localization method requires high computing resources. However, the embedded processor usually has insufficient computing power. To address these issues, proposes a mobile robot localization method that has the feature of low computational complexity. In this method, multi-state constraint Kalman filter is utilized to fuse lidar and IMU data. In addition, the approximate neighbor search method is used to replace the traditional KD tree neighbor search method that can extract the normal vector of laser point cloud. On the premise of meeting the accuracy requirements of plane feature extraction, the extraction speed of normal vector is increased by approximate 6 times. Finally, the location method is tested in the underground garage scene. The overall positioning error of the method is within 0.4 m, and the rotation absolute pose error is between 0.02~0.06 rad. Experimental results show that the proposed method takes lesser computing resource. And it can provide good positioning results in structured environment.

Keywords: localization; Kalman filter; lidar; IMU; planar feature extraction

0 引 言

相对于传统固定式工业机器人, 移动机器人由于其移动的灵活性以及部署的便利性, 在家庭服务、医疗、导购等领域的应用越来越广泛。近年来, 国内外移动机器人在地图构建与定位、路径规划、运动控制等方面取得了一定的研究成果。定位作为移动机器人的基础功能, 具有较高的研究价值, 当前定位研究主要集中于精度、可靠性和计算效率 3 个方面。近几年由于硬件性能的提升,

使得定位算法在计算效率方面的提升效果并不明显, 但在计算资源受限的情况下, 如何提高定位算法的计算效率值得深入研究。

目前用于移动机器人定位的传感器有很多, 卫星定位系统、激光雷达、惯性测量单元 (inertial measurement unit, IMU)、摄像头等都可可为移动机器人定位提供所需的信息。其中激光雷达、IMU 和摄像头因其在局部环境中的数据精度较高且不依赖卫星等外部条件, 因此被广泛地应用于局部场景的定位。

在定位算法方面, 基于先验地图的定位方法是比

收稿日期: 2020-06-22 Received Date: 2020-06-22

^{*} 基金项目: 国家重点研发计划 (2017YFB1301102)、国家科技重大专项 (2017ZX01038201) 资助

较常用的定位方法之一,该方法将在线观测的环境数据与先验地图匹配,得到差异最小的最佳匹配位置。先验地图需要通过即时定位与地图构建(simultaneous localization and mapping, SLAM)或运动恢复结构(structure from motion, SfM)等算法进行构建,一般有路标地图和点云地图两种,分别对应 2 种不同的匹配方法。

基于路标的地图匹配定位方法关键在于是否能够从环境中提取到足够的路标信息。在结构化环境中,丰富的平面、直线等信息都可以作为路标进行匹配定位。在传统方法中,Zhang 等^[1]提出了从激光雷达的单次扫描中提取环境线面特征的方法。Hata 等^[2]提出了提取激光雷达点云数据中的车道线作为路标进行匹配定位的方法。Shan 等^[3]提出了一种基于激光雷达进行环境平面和边缘特征提取的轻量级定位方法。Mur-Artal 等^[4-5]提出 ORB SLAM,使用 ORB 描述子表示路标特征。李帅鑫等^[6]提出了一种改进的单目视觉实时定位与测图方法,该方法使用 ORB 特征作为特征角点,通过迭代卡尔曼滤波进行最优匹配。近年来,使用深度学习技术进行特征提取也表现出不错的效果。如 Uy 等^[7]提出了一种从给定三维点云中提取全局描述符的方法。Yang 等^[8]使用卷积神经网络辅助构建场景三维模型,提高了定位的准确性。Detone 等^[9]提出了一种自监督训练框架,用于训练兴趣点检测器和描述符,这些描述符可用于计算机视觉中大规模多视图几何问题,但深度学习技术对计算资源的较高需求限制了这些方法的使用场景。

基于点云地图的匹配定位方法是目前定位精度最高的方法。Levinson 等^[10]提出了一种概率地图点云匹配的方法,在城市环境下的定位精度达到了 10 cm;另一种应用比较广泛的点云地图匹配方法是三维正态分布变换(normal distributions transform, NDT)匹配方法^[11]。点云地图匹配精度虽然高,但是资源占用率和计算复杂度也很高,如何对地图进行维护更新以应对环境的动态变化也是该方法需要解决的难点问题之一。

将 IMU 数据与图像数据和激光雷达数据进行融合能有效提高定位算法的可靠性和运行效率。为此,Martinelli^[12]研究了视觉-惯性结构在运动问题中的应用,Mourikis 等^[13]提出使用多状态约束的卡尔曼滤波(multi-state constraint Kalman filter, MSCKF)方法来融合视觉-惯性导航,Qin 等^[14]提出 VINS-Mono,通过融合 IMU 预积分值和视觉特征观测结果,得到高精度的视觉里程计,Mur-Artal^[15]提出一种紧耦合的视觉-惯性 SLAM 系统,在回环区域实现零漂移定位。在提高运行效率方面,Biber 等^[16]使用里程计信息来加速定位迭代的收敛速度。

另一种常见的融合方式是将摄像头与激光雷达进行融合。Ku 等^[17]提出了一种使用图像信息和稀疏激光点云的高效深度图生成方法,Zhang 等^[18]提出了将视觉里程计和激光雷达里程计结合起来的通用框架,Shao 等^[19]针对激光雷达在隧道等退化场景中的不稳定性提出了一种将双目视觉惯性里程计与激光雷达结合的 SLAM 方法。何珍等^[20]提出了一种多目视觉与激光组合导航的精确定位方法,该方法将多目视觉识别多个圆形标识点的定位结果与激光扫描结果通过无迹卡尔曼滤波算法进行融合,得到精确的定位结果。这些方法虽然提高了定位系统的稳定性,但是同时使用摄像头和激光雷达需要处理大量的传感器数据,需要占用较多的计算资源。

本文针对计算资源受限的移动机器人,提出了一种低计算复杂度的定位方法。该方法使用 IMU 传感器数据预测移动机器人状态,通过激光雷达数据提取结构化环境中的平面特征并进行跟踪,最后使用 MSCKF 方法对激光雷达和 IMU 数据进行融合,在保持较高定位精度的情况下能有效降低定位算法的计算资源需求。

1 基于 MSCKF 的定位方法整体框架

MSCKF 最初是一种用于视觉惯性里程计中的滤波算法,能够在多个相机位姿约束条件下求解更加精准的位姿估计^[13]。基于 MSCKF 算法框架的定位算法的主要目的是跟踪 IMU 坐标系 $\{I\}$ 相对于全局坐标系 $\{G\}$ 的 3D 位姿变换。由于激光雷达坐标系 $\{L\}$ 与 IMU 坐标系相对固定,因此通过外参标定可得到 $\{L\}$ 与 $\{I\}$ 的相对位姿变换。

基于 MSCKF 的 IMU 与激光雷达紧耦合定位方法的整体框架如图 1 所示,IMU 以 100 Hz 的频率输出加速度和角速度数据,激光雷达以 10 Hz 的频率输出点云数据。每收到一帧点云数据,系统首先扩增一个代表当前激光雷达位姿初始估计的状态向量,然后使用优化后的点云观测模型对平面特征进行提取和跟踪,与预构建地图匹配得到当前状态;每收到一帧 IMU 数据,根据运动模型对 IMU 状态进行估计,同时更新系统状态的协方差矩阵;最终通过 MSCKF 融合 IMU 与激光雷达的观测数据更新系统状态,以 100 Hz 的频率输出定位结果。

基于 MSCKF 的 IMU 与激光雷达紧耦合定位方法的难点如下:

- 1) 如何建立一种低计算复杂度的激光点云观测模型,从而使其能够实时运行于低性能嵌入式平台之上。
- 2) 如何将传统的用于视觉 SLAM 的 MSCKF 方法应用于 IMU 和激光雷达的融合上。




图 1 整体框架

Fig. 1 System framework

2 激光点云观测模型

本文提出的观测模型为点云数据中的平面特征在多个激光雷达状态下的几何约束模型, 本文从平面特征提取、跟踪以及参数化等方面提出了一种快速的激光点云观测模型。

2.1 平面特征提取

本文采用一种快速且鲁棒的方法对稀疏点云中的平面特征进行提取, 主要流程为:

- 1) 对点云中每个点计算其法向量;
- 2) 根据点云中点之间的欧式距离差值以及法向量夹角差值进行聚类;
- 3) 对每个聚类通过主成分分析 (principle component analysis, PCA) 计算关于其点云集合 3D 位置的特征向量和特征值, 判断是否将该聚类的特征作为平面特征提取。

其中步骤 3) 中的具体判别方法为: 若聚类最小特征值与第二大特征值的比值大于一定阈值, 则认为该聚类不是平面; 若小于一定阈值, 则计算最大的两个特征值所对应的特征向量的叉乘得到平面的法向量, 计算聚类中点到该平面的平均距离; 若距离大于一定阈值, 则该平面不够平整, 丢弃该聚类, 否则将该聚类对应的平面作为平面特征提取出来。

在传统的基于随机霍夫变换的点云法向量计算的过程中, 一般是通过对点云集合构建 KD 树的方式来加速查找近邻点, 进而在近邻点中随机采样计算局部平面的法向量并进行霍夫投票。虽然对于单帧点云来说, 构建 KD 树是比较简单快速的, 但要针对点云中每个点进行近邻点搜索时, 多次 KD 树的遍历将会导致累计时间成为整体点云法向量计算的时间瓶颈。

本文使用了一种快速的近似近邻搜索方法替代 KD 树近邻搜索方法, 将点云数据通过球面投影得到其前视图, 然后以点云中每个点在前视图中的像素坐标为中心, 提取宽为 w 高为 h 的矩形框内像素点所对应的点云作为候选近邻点, 最后度量候选近邻点到中心点的距离, 将距离大于一定阈值的作为离群点剔除, 将剩余候选近邻点作为近邻点搜索结果输出。如图 2 所示, 要搜索点 A

的近邻点, 首先把点云投影到球面上, 然后展开球面得到球面投影视图, 在投影视图上选择虚线矩形框内的点 B、C 作为候选近邻点输出, 最后计算 B、C 与 A 的实际距离, 若小于设定值则把 B、C 作为 A 的近似近邻点输出。相比于传统的 KD 树近邻搜索方法, 本文的方法大幅提高了计算速度。




图 2 提取候选近邻点

Fig. 2 Selection of candidate neighbor points

2.2 平面特征跟踪

多状态约束 MSCKF 算法的关键在于通过单个特征在滑动窗口中多个状态下的几何约束对整体状态向量进行更新, 因此需要对观测特征进行跟踪以得到多个状态之间的关联。

本文提出的方法首先根据 2.1 节的方法对第 i 帧点云数据计算法向量并聚类, 之后根据第 $i-1$ 帧点云的平面特征构建 KD 树进行特征跟踪, 具体跟踪步骤如下。

- 1) 对每个聚类作为候选的平面特征计算特征参数 ${}^i\Pi_j$;
- 2) 对每个候选平面的特征通过 KD 树搜索上一时刻一定距离内的候选跟踪平面特征 ${}^{i-1}\Pi_k$ ($k=0, 1, \dots, m$);
- 3) 通过多尺度度量逐一计算 ${}^i\Pi_j$ 与 ${}^{i-1}\Pi_k$ 之间的匹配得分, 并选取 m 个候选跟踪平面特征中选取得分最高且大于设定阈值的特征作为跟踪特征与 ${}^i\Pi_j$ 关联;
- 4) 对于没有候选平面特征或者最高匹配得分小于设定阈值的聚类, 进行后续平面特征检测, 若检测为平面特征则将该聚类作为新的特征提取, 否则视其为离群点丢弃。

上述步骤中提到的多尺度的度量方式包括平面与法向量之间的夹角、平面聚类中心之间的距离、聚类点云到平面 ${}^{i-1}\Pi_k$ 的平均距离等。

2.3 平面特征参数化

传统的 Hesse 平面参数化一般使用平面单位法向量 ${}^G\mathbf{n}^T$ 和平面与坐标系 $\{G\}$ 原点的距离 Gd 表示平面特征, 对平面上任意一点 ${}^G\mathbf{x}$, 满足 ${}^G\mathbf{n}^T \cdot {}^G\mathbf{x} - {}^Gd = 0$ 。但是该方法存在过参数化的问题, 这会导致矩阵计算过程的奇异性问题。因此本文使用 Geneva 等^[21]提出的最近平面点平面参数化方法。

定义平面特征参数 ${}^G\Pi = [{}^G\Pi(x) \ {}^G\Pi(y) \ {}^G\Pi(z)]^T \in \mathbb{R}^3$ 。特征的几何意义是距离坐标系 $\{G\}$ 原点最近一点的坐标, 设 $f_{\Pi}: {}^G\mathbf{n}^T d \mapsto [{}^G\mathbf{n}^T d]$ 。最近平面点表示法

与 Hesse 表示法之间的映射关系为:

$$f_{II} = {}^G n^G d \quad (1)$$

$$f_{II}^{-1} = \left[\frac{1}{\sqrt{{}^G \Pi(x)^2 + {}^G \Pi(y)^2 + {}^G \Pi(z)^2}} {}^G \Pi^T \right]^T \quad (2)$$

由于最近平面点表示法无法表示与坐标系原点相交的平面,本文采用了平面特征在激光雷达局部坐标系下的参数表示,即 Anchored 平面特征。在激光雷达坐标系下,环境平面一般不会与原点相交,与原点过于接近的 Anchored 平面作为离群点剔除。本文的 Anchored 坐标系 $\{A\}$ 为该特征首次被检测到时的激光雷达坐标系。

2.4 平面特征观测模型

本小节在前文的基础上,提出完整的平面特征观测模型。

设 ${}^{L_i} \Pi_j$ 为滑动窗口中激光雷达第 i 个时间序列观测到的第 j 个局部平面特征,对应 Anchored 坐标系 $\{A_m\}$ 下的观测结果记为 ${}^{A_m} \Pi_j$,该平面上任意一点坐标在当前激光雷达坐标系和 Anchored 坐标系分别记为 ${}^{L_i} \mathbf{x}$ 和 ${}^{A_m} \mathbf{x}$,由式(3)所示的几何性质可得平面特征参数在不同坐标系下的变换关系,如式(4)所示。

$$\begin{cases} {}^{L_i} \mathbf{n}_j^T {}^{L_i} \mathbf{x} - {}^{L_i} d_j = 0, \\ {}^{A_m} \mathbf{n}_j^T {}^{A_m} \mathbf{x} - {}^{A_m} d_j = 0, \\ C({}^{L_i} \bar{q}) {}^{L_i} \mathbf{x} + {}^{A_m} \mathbf{p}_{L_i} = {}^{A_m} \mathbf{x} \end{cases} \quad (3)$$

$$\begin{bmatrix} {}^{L_i} \mathbf{n}_j \\ {}^{L_i} d_j \end{bmatrix} = \begin{bmatrix} C({}^{L_i} \bar{q}) & 0 \\ {}^{A_m} \mathbf{p}_{L_i}^T & 1 \end{bmatrix} \begin{bmatrix} {}^{A_m} \mathbf{n}_j \\ {}^{A_m} d_j \end{bmatrix} \quad (4)$$

式中: $C({}^{L_i} \bar{q})$ 和 ${}^{A_m} \mathbf{p}_{L_i}$ 可以通过激光雷达状态 \mathbf{x}_{L_i} 和 \mathbf{x}_{A_m} 得到。根据式(3)、(4)可得激光雷达状态 \mathbf{x}_{L_i} 对 Anchored 平面特征的 ${}^{A_m} \Pi_j$ 的观测方程为:

$${}^{L_i} \mathbf{z}_j = {}^{L_i} \Pi_j = (C({}^{L_i} \bar{q}) {}^{A_m} \mathbf{n}_j) (-{}^{A_m} \mathbf{p}_{L_i}^T {}^{A_m} \mathbf{n}_j + {}^{A_m} d_j) = C({}^{L_i} \bar{q}) {}^{A_m} \mathbf{n}_j {}^{A_m} d_j - C({}^{L_i} \bar{q}) {}^{A_m} \mathbf{n}_j {}^{A_m} \mathbf{p}_{L_i}^T {}^{A_m} \mathbf{n}_j \quad (5)$$

对观测方程在当前估计状态附近近似线性化,得到单个平面特征 ${}^{A_m} \Pi$ 在 \mathbf{x}_{L_i} 下的观测误差

$${}^{L_i} \mathbf{r}_j = {}^{L_i} \mathbf{z}_j - \hat{{}^{L_i} \mathbf{z}_j} = {}^{L_i} \mathbf{H}_j \delta \mathbf{x}_{L_i} + {}^{A_m} \mathbf{H}_j \delta \mathbf{x}_{A_m} + \mathbf{H} \delta {}^{A_m} \Pi_j + \mathbf{n}_{L_i \Pi_j} \quad (6)$$

式中: ${}^{L_i} \mathbf{H}_j$ 、 ${}^{A_m} \mathbf{H}_j$ 、 ${}^{A_m} \Pi_j \mathbf{H}$ 分别为观测方程关于激光雷达状态 \mathbf{x}_{L_i} 、 \mathbf{x}_{A_m} 和 Anchored 特征 ${}^{A_m} \Pi_j$ 的 Jacobi 矩阵; $\mathbf{n}_{L_i \Pi_j}$ 为平面特征的观测噪声。

由于本文中平面特征的 Anchored 坐标系为该特征被首次检测到的激光雷达坐标系,即该特征跟踪窗口中

第一个激光雷达状态,因此该 Anchored 位姿同样也是在本文待优化的激光雷达滑动窗口状态中的。Anchored 特征在跟踪过程中的多个观测误差公式组合即可得到:

$$\mathbf{r}_j = \mathbf{H}_{x_j} \delta \mathbf{x} + \mathbf{H}_{\Pi_j} \delta \Pi_j + \mathbf{n}_{\Pi_j} \quad (7)$$

式中: \mathbf{H}_{x_j} 、 \mathbf{H}_{Π_j} 分别表示第 j 个观测特征关于雷达状态 \mathbf{x} 和平面特征 Π 的雅可比矩阵。将式(7)投影到 \mathbf{H}_{Π_j} 左零子空间中,消除 $\delta \Pi$,得到最终用于对状态向量进行更新的观测模型:

$$\mathbf{r}_{oj} = \mathbf{A}^T \mathbf{r}_j = \mathbf{H}_{oj} \delta \mathbf{x} + \mathbf{n}_{oj} \quad (8)$$

式中: \mathbf{A} 的列向量由 \mathbf{H}_{Π_j} 左零子空间的基向量组成。将当前激光雷达点云所有平面特征观测模型组合即可得到:

$$\mathbf{r}_o = \mathbf{H}_o \delta \mathbf{x} + \mathbf{n}_o \quad (9)$$

式中: \mathbf{r}_o 、 \mathbf{H}_o 、 \mathbf{n}_o 分别由 \mathbf{r}_{oj} 、 \mathbf{H}_{oj} 、 \mathbf{n}_{oj} 作为块矩阵组成。将式(9)观测模型代入经典卡尔曼滤波更新过程即可完成状态向量和协方差矩阵的更新。

3 基于 MSCKF 的紧耦合定位方法

本文将 MSCKF 算法框架应用于激光雷达与 IMU 的融合,使用预构建的点云地图进行定位。整个算法框架分为状态传递和状态更新 2 个过程:

1) 状态传递: 每收到一次 IMU 测量值,执行一次状态传递。通过离散的 IMU 状态模型计算系统状态和协方差矩阵;

2) 状态更新: 每收到一帧点云数据,系统在状态向量滑动窗口扩增一个激光雷达初始位姿估计的状态,在观测模型提取出平面特征结果后对新增状态进行更新。

本节首先给出状态向量表述和误差状态表示,之后根据 IMU 连续时间运动模型描述了系统的状态传递方程^[13, 22],最后根据经典卡尔曼滤波给出系统的状态更新方程。

3.1 状态向量

系统的完整状态分为 3 个部分: 1) IMU 的状态 \mathbf{x}_I ; 2) IMU 与激光雷达的外参状态 $\mathbf{x}_{\text{calib}_L}$; 3) 包含 m 个激光雷达位姿的滑动窗口状态 \mathbf{x}_L ,完整的系统状态为:

$$\mathbf{x} = [\mathbf{x}_I^T \mathbf{x}_{\text{calib}_L}^T \mathbf{x}_L^T]^T \quad (10)$$

其中,

$$\mathbf{x}_I = [{}^L \bar{q}^T \mathbf{b}_g^T \mathbf{v}_I^T \mathbf{b}_a^T \mathbf{p}_I^T]^T$$

$$\mathbf{x}_{\text{calib}_L} = [{}^L \bar{q}^T \mathbf{p}_I^T]^T$$

$$\mathbf{x}_L = [\mathbf{x}_{L_1}^T \cdots \mathbf{x}_{L_m}^T]^T$$

$$\mathbf{x}_{L_i} = [{}^L \bar{q}^T \mathbf{p}_{L_i}^T]^T, i \in \{1, 2, \cdots, m\}$$

式中: ${}^L \bar{q}$ 表示从全局坐标系 $\{G\}$ 到 IMU 坐标系 $\{I\}$ 的旋转的 JPL 单位四元数; ${}^G \mathbf{v}_I$ 和 ${}^G \mathbf{p}_I$ 分别为 IMU 相对于全局坐标系的速度和位置; \mathbf{b}_g 和 \mathbf{b}_a 分别为 IMU 陀螺仪和加速度的偏差; ${}^L \bar{q}$ 和 ${}^L \mathbf{p}_I$ 表示激光雷达坐标系 $\{L\}$ 与 IMU 坐标

系 $\{I\}$ 之间的三维刚体变换; ${}^{L_i}{}_{G}^{\sim}$ 和 ${}^G p_{L_i}$ 分别表示滑动窗口中第 i 个激光雷达状态与全局坐标系 $\{G\}$ 之间的旋转和位置关系。

3.2 误差状态表示

定义了状态向量之后, 可以表示状态的真实值与估计值之间的关系。状态的真实值表示为 x , 估计值表示为 \hat{x} , 对应的误差状态表示为 δx , 三者的关系为:

$$x = \hat{x} \boxplus \delta x \quad (11)$$

式中: \boxplus 为通用加法运算符, 对于定义在欧氏空间中的速度、位置等状态, 其含义为欧氏空间中的加法, 如 $p = \hat{p} + \delta p$; 对于四元数, 则定义为 $\bar{q} = \delta \bar{q} \otimes \hat{q}$, \otimes 为 JPL 四元数乘法, 误差状态 $\delta \bar{q} \equiv \left[\frac{1}{2} \delta \theta^T \ 1 \right]^T$ 。

最后定义关于误差状态的协方差矩阵, 用于度量滤波器对当前状态估计的不确定性。根据上文对系统状态的划分, k 时刻误差状态协方差矩阵的定义为:

$$P_{klk} = \begin{bmatrix} P_{ll_{klk}} & P_{ll_{klk}} \\ P_{ll_{klk}}^T & P_{ll_{klk}} \end{bmatrix} \quad (12)$$

式中: $P_{ll_{klk}}$ 为 IMU 误差状态 δx_l 和外参误差状态 $\delta x_{\text{calib}_L}$ 的协方差, 维度大小为 21×21 。 $P_{ll_{klk}}$ 为激光雷达误差状态 δx_L 的协方差, 维度大小为 $6 \text{ m} \times 6 \text{ m}$ 。 $P_{ll_{klk}}$ 为 δx_l 和 $\delta x_{\text{calib}_L}$ 与 δx_L 之间的协方差, 维度大小为 $21 \times 6 \text{ m}$ 。

3.3 状态传递

IMU 在输出关于加速度和角速度的测量之后, MSCKF 根据 IMU 的运动模型进行状态传递, 关于 IMU 估计状态的连续时间运动模型为:

$$\begin{aligned} {}^I \dot{\hat{q}} &= \frac{1}{2} \Omega(\hat{\omega}) \hat{q} \\ \dot{\hat{b}}_g &= \mathbf{0}_{3 \times 1} \\ \dot{\hat{v}} &= C({}^I \hat{q})^T \hat{a} + {}^G g \\ \dot{\hat{b}}_a &= \mathbf{0}_{3 \times 1} \\ \dot{{}^G \hat{p}}_l &= {}^G \hat{v}_l \end{aligned} \quad (13)$$

式中: $\hat{a} \in \mathbb{R}^3$ 和 $\hat{\omega} \in \mathbb{R}^3$ 分别为 IMU 输出的无偏加速度

和角速度的估计值; $\Omega(\hat{\omega}) = \begin{bmatrix} -[\hat{\omega}_\times] & \hat{\omega} \\ \hat{\omega}^T & 0 \end{bmatrix}$; $[\hat{\omega}_\times]$ 为 $\hat{\omega}$

的偏置矩阵; $C(\cdot)$ 为将四元数转换为对应旋转矩阵的函数; ${}^G g$ 为重力加速度。需要注意的是, 虽然上式给出了系统的连续时间运动模型, 但由于 IMU 的测量数据是离散的, 实际计算估计状态传递时一般使用四阶龙格-库塔等数值积分方法对定积分进行近似处理。类似的, 可以得到误差状态协方差矩阵的传递公式:

$$P_{k+1|k} = \begin{bmatrix} P_{ll_{k+1|k}} & \Phi_k P_{ll_{klk}} \\ P_{ll_{klk}}^T \Phi_k^T & P_{ll_{klk}} \end{bmatrix} \quad (14)$$

式中: $P_{ll_{k+1|k}} = \Phi_k P_{ll_{klk}} \Phi_k^T + Q_k$, Φ_k 为系统的状态转移方程; Q_k 为系统的噪声协方差矩阵。

3.4 状态更新

在接收点云数据并进行特征提取之后, 得到点云数据的观测量, 之后根据观测量对整个系统进行状态更新。根据本文的观测模型可以得到相应的观测方程:

$$r_o = H_o \delta x + n_o \quad (15)$$

式中: r_o 为观测量; H_o 为观测量关于状态量的雅可比矩阵; n_o 为噪声。

由于本文使用了滑动窗口保存多个时间序列的状态, 状态更新矩阵维度可能会很高, 导致较高的计算复杂度, 因此在处理之前使用 QR 分解降维:

$$H_o = [Q_1 \ Q_2] \begin{bmatrix} R \\ 0 \end{bmatrix} \quad (16)$$

代入式(14)可得:

$$r_o = [Q_1 \ Q_2] \begin{bmatrix} R \\ 0 \end{bmatrix} \delta x + n_o \quad (17)$$

$$\begin{bmatrix} Q_1^T r_o \\ Q_2^T r_o \end{bmatrix} = \begin{bmatrix} R \\ 0 \end{bmatrix} \delta x + \begin{bmatrix} Q_1^T n_o \\ Q_2^T n_o \end{bmatrix} \quad (18)$$

式中: $Q_2^T r_o$ 为噪声项; 因此使用 $Q_1^T r_o$ 进行状态更新, 卡尔曼增益为:

$$K = P_{k+1|k} R^T (R P_{k+1|k} R^T + Q_1^T R_o Q_1)^{-1} \quad (19)$$

式中: $R_o = \sigma_n^2 I$ 为噪声的协方差矩阵。同时状态更新量为:

$$\Delta X = K Q_1^T r_o \quad (20)$$

协方差矩阵更新为:

$$P_{k+1|k+1} = (I - KR) P_{k+1|k} (I - KR)^T + K Q_1^T R_o Q_1 K^T \quad (21)$$

4 实验测试

在地下车库场景下, 本文使用搭载了 16 线激光雷达、IMU 和轮速编码器等传感器的轮式移动机器人, 测试了本文提出的平面特征提取跟踪方法和整体的定位效果。

4.1 平面特征提取测试

本文提出的平面特征提取方法保证了提取的平面特征精度在可接受范围内的同时提高了在嵌入式处理器平台上的运算速度。平面特征提取主要分为点云法向量提取、点云聚类及聚类分析 3 个阶段, 本节对法向量提取和总体的平面特征提取效果进行了测试。

在法向量提取测试中, 本文分两次采集了地下车库场景的点云数据, 将计算复杂度高但更加精准的法向量

计算结果作为基准值,记录2次实验中近似近邻搜索方法和KD树近邻搜索方法的时间与精度数据,测试结果对比如表1所示。


表1 法向量提取性能对比

Table 1 Performance comparison of normal vector extraction


序号	点云 帧数	平均点 云大小	计算平均时间/ms		计算精度/rad	
			KD树近邻	近似近邻	KD树近邻	近似近邻
1	840	12 026	153.47	27.64	0.032	0.058
2	240	11 547	148.93	23.82	0.045	0.077

其中实验1测试了840帧点云,平均每帧12 026个点;实验2测试了240帧点云,平均每帧11 547个点。从实验结果可以看出,本文提出的法向量计算方法的速度提高了6倍左右,虽然该阶段损失了部分精度,但法向量提取结果是平面特征提取的中间结果,从下文的描述可以看出损失的精度对最终平面特征提取结果影响很小。

两种方法的特征提取效果如图3所示,本文的方法加快了法向量计算速度,与KD树近邻搜索相比,法向偏差精度损失约为0.026 rad,但对平面特征提取基本没有影响。



(a) 近似近邻搜索
(a) Approximate neighbor search



(b) KD树近邻搜索
(b) KD tree neighbor search

图3 平面特征提取测试效果对比

Fig. 3 Comparison of test results of plane features extraction

图3(a)和图3(b)分别为使用近似近邻搜索和KD树近邻搜索计算出的法向量提取的平面特征(图中绿色椭圆部分),其中椭圆中心代表平面特征的位置,椭圆的长短轴之比表示了法向量聚类分析后的特征值比值。图3(a)和(b)对比表明,近似近邻搜索方法提取出的平面特征数量和平面特征的位置与KD树近邻搜索的结果基本一致,法向量提取步骤损失的部分精度对平面特征提取的结果影响很小。

4.2 定位效果测试

在进行定位效果测试之前,需要使用本文提出的平面特征观测模型构建平面特征地图。地下车库测试场景的平面特征地图如图4所示,图4中的绿色椭圆表示平面特征。在实际测试中,本文按照图4红色箭头标识的路线测试定位效果,P0为测试起点和终点,P1、P2、P3和P4均有特殊场景,用于测试定位效果的鲁棒性,P1和P2为地下车库的两个入口,P3处摆放了各种杂物,平面特征较少,P4位置进行了大幅度转弯,此时IMU的测量误差较大。



图4 平面特征地图

Fig. 4 Plane feature map

本文提出的定位方法在地下车库场景进行了定位的绝对位姿误差测试,测试数据采集的定位数据路径长度305.30 m,采集时长199.41 s,包含了1 996个位姿数据,然后采用SLAM领域中常用的EVO评测工具对整体定位效果进行分析,结果如图5所示。图5展示了定位的平移绝对位姿误差和旋转绝对位姿误差,并分别使用轨迹图和折线图2种方式来进行说明。图5(a)和(c)轨迹图直观地展示了测试过程中定位误差随位置变化而变化的关系,其中虚线轨迹是定位数据的基准值,带颜色的轨迹是本文定位方法的输出结果,颜色不同代表了定位结果与基准值的差异,从红色到蓝色误差逐渐减小。从图5(a)和(c)可以看出,在地下车库的多数路段定位效果良好,在P1、P2等靠近出口的位置平移定位误差有所

增加,在 P4 处大幅度转弯过后由于 IMU 产生较大测量误差导致旋转误差有所增加。

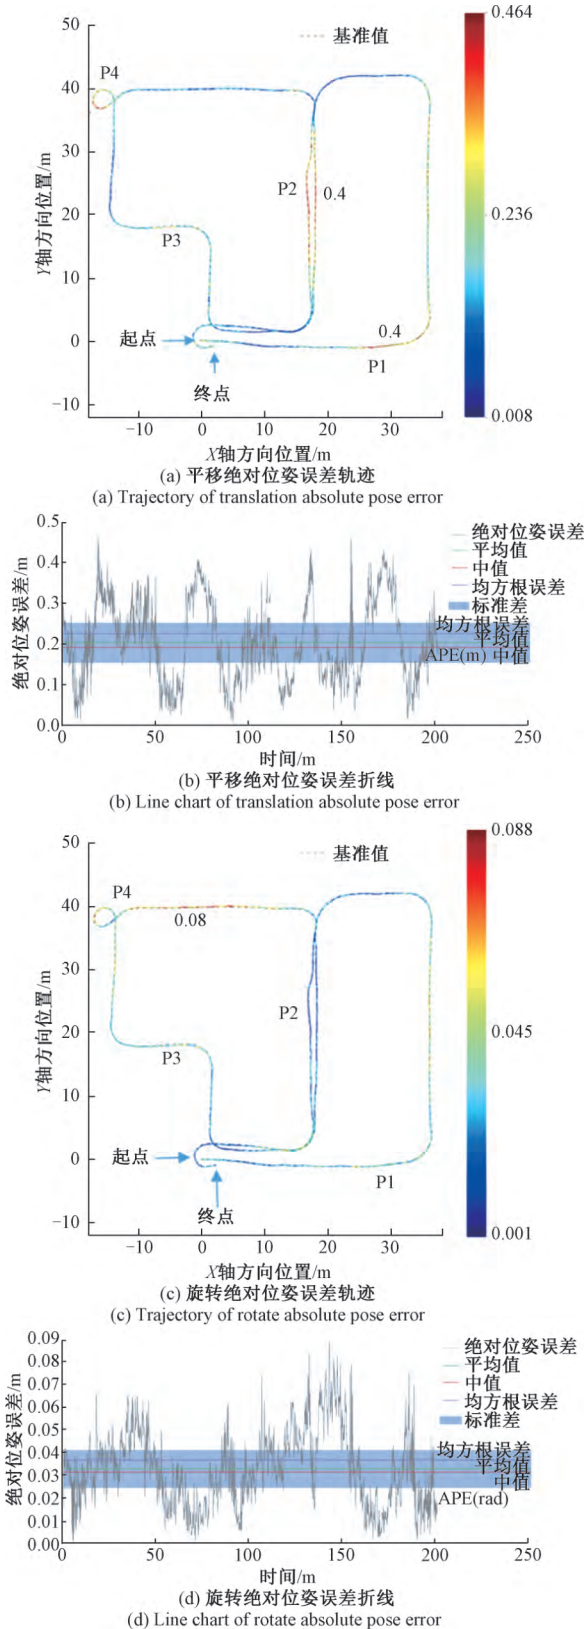


图 5 定位效果测试

Fig. 5 Localization effect test

图 5(b) 和 (d) 定量地展示了定位测试过程中绝对位姿误差随时间的变化关系。折线图展示了平移和旋转位姿误差的实时误差变化、误差平均值、中值、均方根误差以及误差标准差分布。以标准差为参考,平移绝对位姿误差集中分布在 $0.203 \text{ m} \pm 0.047 \text{ m}$, 旋转绝对位姿误差集中分布在 $0.0328 \pm 0.0082 \text{ rad}$ 之间。

从测试结果可以看出,该定位方法在地下车库场景中直线和小幅转弯情况下的定位效果比较好,定位位置误差基本保持在 0.2 m 左右,超过 0.2 m 的位置是由于靠近出口平面特征较少或者大幅转弯时 IMU 测量误差较大导致,但整体定位误差仍控制在 0.4 m 以内。旋转绝对位姿误差集中在 $0.02 \sim 0.06 \text{ rad}$ 之间,最大不超过 0.09 rad 。

5 结 论

本文提出了一种基于 MSCKF 的 IMU 与激光雷达紧耦合定位方法。根据多线激光雷达点云数据的特点,提出了针对结构化环境的平面特征观测模型,可以快速提取平面特性并进行跟踪,在较少精度损失的同时提高了在资源受限计算平台上的计算速度。地下车库场景中的实验结果表明,本文提出的方法占用较少的计算资源,在结构化环境中能够提供良好的定位结果。未来工作需要进一步分析影响定位精度的因素,在提高计算速度的同时减少定位精度的损失。

参考文献

- [1] ZHANG J, SINGH S. LOAM: Lidar odometry and mapping in real-time [C]. Proceedings of Robotics: Science and Systems Conference, 2014: 109-111.
- [2] HATA A, WOLF D. Road marking detection using lidar reflective intensity data and its application to vehicle localization [C]. 2014 IEEE 17th International Conference on Intelligent Transportation Systems, 2014: 584-589.
- [3] SHAN T X, ENGLOT B. LeGO-LOAM: Lightweight and ground-optimized lidar odometry and mapping on variable terrain [C]. IEEE International Conference on Intelligent Robots and Systems, 2018: 4758-4765.
- [4] MUR-ARTAL R, MONTIEL J M M, TARDOS J D. ORB-SLAM: A versatile and accurate monocular SLAM system [J]. IEEE Transactions on Robotics, 2015, 31(5): 1147-1163.
- [5] MUR-ARTAL R, TARDOS J D. ORB-SLAM2: an open-source SLAM system for monocular, stereo, and RGB-D cameras [J]. IEEE Transactions on Robotics, 2017, 33(5): 1255-1262.
- [6] 李帅鑫, 李广云, 周阳林, 等. 改进的单目视觉实时

- 定位与测图方法[J]. 仪器仪表学报, 2017, 38(11): 2849-2857.
- LI SH X, LI G Y, ZHOU Y L, et al. Improved monocular simultaneous localization and mapping solution [J]. Chinese Journal of Scientific Instrument, 2017, 38(11): 2849-2857.
- [7] UY M A, LEE G H. PointNetVLAD: Deep point cloud based retrieval for large-scale place recognition [C]. IEEE Conference on Computer Vision and Pattern Recognition, 2018: 4470-4479.
- [8] YANG S C, SONG Y, KAESS M, et al. Pop-up SLAM: Semantic monocular plane SLAM for low-texture environments [C]. 2016 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2016: 1222-1229.
- [9] DETONE D, MALISIEWICZ T, RABINOVICH A. SuperPoint: Self-supervised interest point detection and description [C]. IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops, 2018: 337-349.
- [10] LEVINSON J, THRUN S. Robust vehicle localization in urban environments using probabilistic maps [C]. 2010 IEEE International Conference on Robotics and Automation, 2010: 4372-4378.
- [11] MAGNUSSON M. The three-dimensional normal-distributions transform — an efficient representation for registration, surface analysis, and loop detection [D]. Örebro: Örebro University, 2009.
- [12] MARTINELLI A. Closed-form solution of visual-inertial structure from motion [J]. International Journal of Computer Vision, 2014, 106(2): 138-152.
- [13] MOURIKIS A I, ROUMELIOTIS S I. A multi-state constraint Kalman filter for vision-aided inertial navigation [C]. IEEE International Conference on Robotics and Automation, 2007: 3565-3572.
- [14] QIN T, LI P, SHEN S. VINS-Mono: a robust and versatile monocular visual-inertial state estimator [J]. IEEE Transactions on Robotics, 2018, 34(4): 1004-1020.
- [15] MUR-ARTAL R, TARDOS J D. Visual-inertial monocular SLAM with map reuse [J]. IEEE Robotics and Automation Letters, 2017, 2(2): 796-803.
- [16] BIBER P, STRASSER W. The normal distributions transform: a new approach to laser scan matching [C]. IEEE International Conference on Intelligent Robots and Systems, 2003: 2743-2748.
- [17] KU J, HARAKEH A, WASLANDER S L. In defense of classical image processing: Fast depth completion on the CPU [C]. 2018 15th Conference on Computer and Robot Vision, 2018: 16-22.
- [18] ZHANG J, SINGH S. Visual-lidar odometry and mapping: Low-drift, robust, and fast [C]. IEEE International Conference on Robotics and Automation, 2015: 2174-2181.
- [19] SHAO W, VIJAYARANGAN S, LI C, et al. Stereo visual inertial LiDAR simultaneous localization and mapping [C]. 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2019: 370-377.
- [20] 何珍, 楼佩煌, 钱晓明, 等. 多目视觉与激光组合导航 AGV 精确定位技术研究 [J]. 仪器仪表学报. 2017, 38(11): 2830-2838.
- HE ZH, LOU P H, QIAN X M, et al. Research on precise positioning technology for AGV based on multi-object vision and laser integrated navigation [J]. Chinese Journal of Scientific Instrument, 2017, 38(11): 2830-2838.
- [21] GENEVA P, ECKENHOFF K, YANG Y L, et al. LIPS: Lidar-inertial 3D plane SLAM [C]. IEEE International Conference on Intelligent Robots and Systems, 2018: 123-130.
- [22] SUN K, MOHTA K, PFROMMER B, et al. Robust stereo visual inertial odometry for fast autonomous flight [J]. IEEE Robotics and Automation Letters, 2018, 3(2): 965-972.

作者简介



吕攀, 2006 年于浙江大学获得硕士学位, 现为浙江大学博士研究生, 主要研究方向为智能系统、移动机器人、嵌入式实时系统。

E-mail: lvp@zju.edu.cn

Lyu Pan received his M.Sc. degree from Zhejiang university in 2006. He is currently a Ph.D. student at Zhejiang University. His main research interests include intelligent system, mobile robot, and embedded real-time system.



李红(通信作者), 2010 年于浙江大学获得博士学位, 现为浙江大学计算机学院副研究员。主要研究方向为嵌入式实时系统、智能系统、人造器官操作系统。

E-mail: lihong@zju.edu.cn

Li Hong (Corresponding author) received her Ph.D. degree from Zhejiang University in 2010. She is currently an associate research fellow the Department of Computer Science at Zhejiang University. Her research interests include embedded real-time system, intelligent system, and cyborg OS.